

멀티에이전트 환경에서의 적대적 커리큘럼 강화학습 기반 게임 AI 안정성 증강

김중원

한국에너지공과대학 소속

e-mail : kkcasl@ieee.org

Enhancing Game AI Stability Based on Adversarial Curriculum Reinforcement Learning in Multi-Agent Environments

Jongwon Kim

Korea Institute of Energy Technology University

Abstract

This paper proposes an adversarial curriculum reinforcement learning framework to improve stability and generalization in multi-agent reinforcement learning (MARL) game environments. The method, Adversarial Curriculum PPO (ACPPO), adjusts training difficulty by controlling enemy composition based on agent performance. The environment consists of heterogeneous enemies with distinct action requirements, making optimal action selection challenging under dynamic conditions. ACPPO is based on a PPO actor-critic model with context-dependent skill-based action selection. A reward function encourages correct actions and penalizes damage and inefficiency.

Experiments in an Unreal Engine 5 environment show that ACPPO achieves 91.8% accuracy, outperforming PPO-only at 67.5%, with improved stability and convergence, demonstrating enhanced robustness and generalization in MARL game settings.

근래 게임 AI, 멀티에이전트 강화학습(Multi-Agent Reinforcement Learning, MARL), 자율 에이전트 기반 시뮬레이션 등 다양한 분야에서 강화학습 기반 게임 환경의 활용이 확대되고 있다. 특히 복수의 에이전트가 협력 또는 경쟁하는 환경에서는, 환경 변화에 대한 적응 능력과 안정적인 정책 학습이 핵심 요소로 작용한다. 그러나 기존의 강화학습 기반 게임 AI는 환경의 복잡도가 증가할수록 exploration difficulty와 sparse reward 문제로 인해 학습 안정성이 크게 저하되며, 특정 전략에 과적합되거나 설계자가 의도하지 않은 방향으로 정책이 수렴하는 문제가 존재한다.

기존 연구들은 주로 고정된 난이도의 환경 또는 self-play 기반 경쟁 구조를 활용하여 정책을 학습한다 [1, 2]. 이러한 방식은 단순한 환경에서는 효과적이지만, 복잡 전략 상황에서는 초기 탐색 실패로 인해 유의미한 보상 신호를 획득하지 못하거나 다양한 상황에 대한 일반화 성능이 저하되는 한계가 있다.

이에 본 연구는 에이전트의 경험 분포(experience distribution)를 단계적으로 조절하는 적대적 커리큘럼 강화학습(adversarial curriculum reinforcement learning) 기반 게임 AI 학습 프레임워크를 제안한다. 제안하는 방법은 초기에는 단순한 환경을 제공하고, 이후 에이전트의 성능에 따라 점진적으로 더 복잡하고 적대적인 환경을 생성함으로써 학습 난이도를 동적으로 증가시킨다.

이에 본 연구는 다음의 핵심 연구 질문을 다루고자

I. 서론

한다.

“멀티에이전트 게임 환경에서 적대적 커리큘럼 강화 학습을 통해, 에이전트의 학습 안정성과 전략 일반화 성능을 동시에 향상시킬 수 있는가?”

이를 위해 본 연구는 멀티에이전트 환경에서의 적대적 커리큘럼 강화학습 기반 게임 AI 프레임워크를 제안한다. 제안하는 방법은 에이전트의 성능에 따라 환경 난이도를 동적으로 조절하며, curriculum progression을 기반으로 점진적인 전략 학습을 수행한다. 또한 cooperative/competitive 구조를 동시에 고려하여 다양한 전략 상황에 대한 적응 능력을 강화한다.

본 연구의 주요 기여는 다음과 같다.

- 적대적 커리큘럼 기반 게임 AI 학습 프레임워크 제안: 게임 AI 학습을 환경 난이도와 경험 분포를 동적으로 조절하는 순차적 강화학습 문제로 정의한다.
- 멀티에이전트 기반 자동 난이도 생성 구조 설계: 적대적 환경 생성기를 통해 에이전트 수준에 적합한 전략 환경을 자동으로 생성한다.
- 점진적 난이도 증가 기반 안정적 정책 학습: curriculum progression을 통해 sparse reward 및 exploration 문제를 완화한다.
- 전략 일반화 및 강인성 향상 검증: 다양한 적 조합 및 환경 변화 상황에서 정책의 일반화 성능 향상을 검증한다.

II. 본론

2.1 방법론 개요




그림 1. 방법론 다이어그램

본 연구는 멀티에이전트 게임 환경에서 상황에

적합한 행동 선택(action selection)을 안정적으로 학습하기 위한 적대적 커리큘럼 강화학습(adversarial curriculum reinforcement learning) 기반 게임 AI 프레임워크를 제안한다. 기존의 강화학습 기반 게임 AI는 복수의 적 유형과 복잡한 행동 선택이 동시에 요구되는 환경에서 exploration difficulty와 sparse reward 문제로 인해 특정 행동에 편향되거나, 설계자가 의도하지 않은 방식으로 정책이 수렴하는 문제가 존재한다. 특히 서로 다른 유형에 따라 상이한 대응 행동이 요구되는 환경에서는 reward attribution ambiguity가 발생하여 정책 학습의 안정성이 크게 저하될 수 있다. 이에 본 연구는 복합 행동 학습 문제를 개별 행동 단위로 분해한 뒤, 이를 단계적으로 통합한 이후 적대적 학습 방식을 적용하는 curriculum-based adversarial learning 구조를 제안하고자 한다.

2.2 실험 환경 정의

본 연구에서의 실험환경으로 에이전트가 맵 중앙에 고정된 상태에서, 두가지 유형의 적(enemy)이 맵 가장자리에서 생성되어 에이전트를 공격하는 게임 환경을 구성한다. 적은 크게 두 가지 유형으로 구성된다. 첫 번째는 근거리 공격(melee attack)을 수행하는 적으로, 에이전트는 해당 적에 대해 근접 공격(melee counter skill)을 사용해야만 피해 없이 대응할 수 있다. 두 번째는 원거리 공격(ranged attack)을 수행하는 적으로, 에이전트는 투사체를 반사하는 튕겨내기(reflect skill)를 사용해야만 공격을 방어할 수 있다. 즉 각 적 유형에 대해 요구되는 대응 행동이 명확히 구분되며, 에이전트는 현재 상황에 적합한 행동을 선택해야 한다. 초기 학습 단계에서는 단일 적 유형만 등장하는 환경을 구성하여 각 행동을 독립적으로 학습시킨다. 예를 들어, 근거리 적만 등장하는 환경에서는 근접 공격 행동만을 집중적으로 학습하며, 원거리 적만 등장하는 환경에서는 튕겨내기 행동을 위주로 학습한다. 이후 학습이 진행됨에 따라 두 유형의 적이 동시에 등장하는 혼합 환경(mixed environment)을 구성하여, 에이전트가 상황에 따라 적절한 행동을 선택하도록 학습을 확장한다.

2.3 적대적 커리큘럼 생성기

본 연구에서는 학습 환경의 난이도를 고정하지 않고, 에이전트의 현재 성능에 따라 적(enemy)의 생성 수와 비율을 동적으로 변화시키는 적대적 커리큘럼 생성기(adversarial curriculum generator)를 설계하였다. 기존의 고정 난이도 기반 강화학습 환경은 특정 상황에 대한

과적합(overfitting)이 발생하기 쉬우며, 학습이 진행된 이후에도 동일한 패턴의 경험만 반복적으로 제공된다는 한계가 존재한다. 이에 반해 제안하는 방법은 에이전트의 현재 학습 수준을 기반으로 적 유형별 등장 비율 및 개체 수를 에이전트에 대해 적대적으로 조절하여, 학습 과정 전체에서 지속적인 난이도 적응이 가능하도록 구성하였다.

적대적 생성기(Adversarial Generator)는 현재 에이전트의 보상 값 R_t^{agent} 를 기반으로 다음 시점의 적 생성 수 벡터인 E_t 를 결정한다. 생성 수 벡터는 근거리 및 원거리 적의 수로 정의된다.

$$E_t = [n_{melee}, n_{range}]$$

본 연구에서는 curriculum learning을 적의 유형별로 분리하여 정의한다. 전체 커리큘럼 집합 C 는 다음과 같다.

$$\begin{aligned} C &= \{C_{melee}, C_{range}, C_{mixed}\} \\ C_{melee} &= \{T_1, T_2, \dots, T_l\} \\ C_{range} &= \{T_{l+1}, T_{l+2}, \dots, T_m\} \end{aligned}$$

근거리 적 학습 단계에서는 melee enemy만 등장하는 환경을 사용하며, 원거리 적 학습 단계에서는 ranged enemy만 등장하는 환경을 사용한다.

$$C_{mixed} = \{T_{m+1}, T_{m+2}, \dots, T_n\}$$

최종 mixed curriculum 단계에서는 두 유형의 적이 동시에 등장하는 복합 환경을 구성하여, 에이전트가 상황에 따라 적절한 행동을 선택하도록 학습한다.

적대적 생성기의 보상 함수는 에이전트의 현재 보상과 목표 보상 간의 성능 차이에 가중치 k 를 곱해 정의한다.

$$R_t^{adv} = k \frac{1}{|N_t - R_t^{agent}|}$$

항 N_t 는 초기값 이후 $N_{t+1} = R_t^{adv} + \alpha$ 꼴로 정의된다. 두 항의 차가 적을수록 적대적 생성기의 보상이 커지는 구조기에 적대적 생성기는 지나치게 단순하거나 불가능한 환경이 아닌, 학습 가능한 수준의 난이도를 지속적으로 생성하도록 유도된다.

2.4 상태(State) 정의

본 연구에서 에이전트는 게임 환경 내 적(enemy)의 상태 정보를 실시간으로 관측하며, 이를 기반으로 현재 상황에 적합한 행동을 선택한다. 각 적 객체 E_i 에

대한 관측 벡터 O_i 는 다음과 같이 정의한다.

$$O_i = (p_i, t_i, v_i, h_i)$$

여기서 p_i 는 적의 상대 위치(relative position), t_i 는 적 유형(enemy type), v_i 는 적의 이동 속도(velocity), h_i 는 적의 현재 상태(state flag)를 의미한다. 적 유형 t_i 는 melee enemy와 ranged enemy를 구분하기 위한 변수로 정의된다.

$$t_i \in \{Melee, Ranged\}$$

Melee enemy는 근거리 접근 후 직접 공격을 수행하며, ranged enemy는 원거리 투사체(projectile)를 발사한다. 에이전트는 적 유형에 따라 서로 다른 대응 행동을 수행해야 한다. 상대 위치 p_i 는 에이전트 중심 좌표계를 기준으로 한 적의 상대 위치 벡터로 정의된다.

$$p_i = (x_i, y_i)$$

여기서 x_i, y_i 는 에이전트를 원점으로 하는 2차원 공간상의 상대 좌표를 의미한다. 또한 ranged enemy의 투사체 접근 여부를 반영하기 위해 projectile state q_i 를 정의한다.

$$q_i \in \{0, 1\}$$

여기서 $q_i = 1$ 은 에이전트를 향해 투사체가 접근 중인 상태를 의미하며, $q_i = 0$ 은 투사체가 존재하지 않는 상태를 의미한다. 최종적으로 상태 표현 벡터 s_t 는 현재 환경 내 적 객체들의 관측 벡터와 projectile state를 포함하여 다음과 같이 구성된다.

$$s_t = \{O_1, O_2, \dots, O_N, q_1, q_2, \dots, q_N\}$$

2.5 행동(Action) 정의

본 연구에서 에이전트의 행동(action) 집합 A 는 다음과 같이 정의된다.

$$A = \{a_{melee}, a_{reflect}, a_{idle}\}$$

여기서 a_{melee} 는 근거리 적에 대응하기 위한 근접 공격(melee counter action), $a_{reflect}$ 는 원거리 투사체를 반사하기 위한 reflect action, a_{idle} 은 추가 행동을 수행하지 않는 idle action을 의미한다. 본 연구에서는 이러한 행동 선택 문제를 sequential decision making 문제로 정의한다.

2.6 보상 함수(Reward Function 정의)

보상 함수 R_t 를 다음과 같이 정의한다.

$$R_t = \alpha R_{correct} - \beta R_{damage} - \delta R_{time}$$

여기서 $R_{correct}$ 는 적절한 행동 선택에 대한 보상, R_{damage} 는 피격 또는 잘못된 행동 선택에 대한 패널티를 의미하며, R_{time} 은 시간 패널티이다. α , β , δ 는 각 항의 가중치이다.

따라서 정책 파라미터 θ 에 대한 업데이트는 다음과 같이 정의된다.

$$\theta \leftarrow \theta + \eta \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \left(\sum_{k=0}^{\infty} \gamma^k R_{t+k} - V(s_t) \right)$$

여기서 η 는 learning rate, γ 는 discount factor, $V(s_t)$ 는 상태 가치 함수(state-value function)를 의미한다.

제안하는 보상 구조는 단순 생존이 아닌, 상황에 적합한 행동 선택 정책(context-aware action-selection policy)을 학습하도록 유도하며, mixed environment에서도 안정적인 행동 우선순위 판단 능력을 형성하도록 설계되었다.

III. 시뮬레이션 구현

3.1 실험 환경

시뮬레이션을 위한 실험 환경으로 Unreal Engine 5와 PyTorch 기반 강화학습 API를 사용하였다. 메인 에이전트는 맵 중앙에 고정된 상태에서 동적으로 생성되는 enemy AI에 대응하도록 설계하였다. 적(enemy)은 melee enemy와 ranged enemy의 두 유형으로 구성되며, 각각 근접 공격과 원거리 투사체 공격을 수행한다.




그림 2. 학습 환경(Mixed)

강화학습 모델은 PPO(Proximal Policy Optimization) 기반 Actor-Critic 구조를 사용하였으며, 정책 네트워크(policy network)는 MLP(Multi-Layer Perceptron) 기반으로 구현하였다. 상태 입력(state input)은 적의 상대 위치, 적 유형, projectile 접근 여부 등으로 구성된 상태 벡터(state vector)를 사용하며, 에이전트는 이를 기반으로 melee counter, reflect, idle action 중 하나를 선택한다.

Component	Specification
CPU	AMD Ryzen 7 260w/ Radeon 780M Graphics
GPU	NVIDIA GeForce RTX 5060 Laptop GPU
RAM	32GB DDR5
OS	Windows 11

표 1. 시뮬레이션 환경 사양

3.2 학습 결과

표 1과 같은 환경에서 시뮬레이션 기반 학습을 진행하였으며, 그 결과는 다음과 같다.



그림 3. 보상 그래프

Method	Accuracy (280,000 steps each)
PPO only	67.5%
ACPPO	90.8%

표 2. PPO only와의 정확도 비교

그림 3은 학습 step에 따른 cumulative reward 변화를 나타내며, 제안하는 ACPPO(Adversarial Curriculum PPO) 구조가 학습이 진행됨에 따라 안정적으로 reward를 향상시키는 경향을 보였음을 확인할 수 있다. 또한 표 2는 PPO only와 제안하는 ACPPO

간의 행동 선택 정확도(Action Selection Accuracy)를 비교한 결과를 나타낸다. 정확도는 전체 행동 선택 횟수 N_{total} 중 상황에 적합한 행동을 수행한 횟수 $N_{correct}$ 의 비율로 정의된다.

$$Accuracy = \frac{N_{correct}}{N_{total}}$$

실험 결과, PPO only는 67.5%의 정확도를 보인 반면 ACPPO는 90.8%의 정확도를 기록하였다. 이는 제안하는 adversarial curriculum 구조가 단순 reward 증가뿐만 아니라, 현재 상황에 적합한 행동(action selection)을 보다 안정적으로 학습하는 데 효과적임을 의미한다.

특히 PPO only의 경우 mixed environment에서 특정 행동에 편향되는 현상이 일부 관찰되었으며, melee enemy와 ranged enemy가 동시에 등장하는 상황에서 잘못된 행동을 선택하는 빈도가 증가하였다. 반면 ACPPO는 curriculum-based skill learning을 통해 각 행동 스킬을 독립적으로 안정화한 이후 mixed environment로 확장하였기 때문에, 복합 상황에서도 행동 우선순위를 보다 정확하게 판단할 수 있었다.

또한 adversarial curriculum generator를 통해 적 생성 수와 enemy composition이 지속적으로 변화하면서, 에이전트는 특정 패턴에 과적합되지 않고 다양한 상황에 대한 일반화 성능(generalization performance)을 향상시킬 수 있었다. 결과적으로 제안하는 ACPPO는 기존 PPO 기반 학습 방식 대비 더 높은 행동 정확도와 안정적인 reward convergence를 동시에 달성하였음을 확인하였다.

IV. 결론 및 향후 연구 방향

본 연구에서는 멀티에이전트 게임 환경에서 상황 기반 행동 선택(action selection)을 안정적으로 학습하기 위한 적대적 커리큘럼 강화학습 기반 게임 AI 프레임워크를 제안하였다. 기존 강화학습 기반 게임 AI는 복잡한 적 조합 환경에서 exploration difficulty와 sparse reward 문제로 인해 특정 행동에 편향되거나 환경 변화에 취약한 정책으로 수렴하는 문제가 존재한다. 이를 해결하기 위해 본 연구는 melee enemy와 ranged enemy에 대한 행동 스킬을 개별적으로 학습한 뒤, mixed environment에서 통합 학습을 수행하는 curriculum-based adversarial learning 구조를 설계하였다. 제안하는 방법은 단순 행동 반복이 아닌 상황 기반 행동 선택 정책(context-aware action selection policy)을

학습하도록 설계되었으며, 다양한 적 조합 환경에서도 강건한 정책(robust policy)을 형성할 수 있도록 한다.

향후 연구에서는 이동, 회피, 광역 공격 등 다양한 행동 스킬을 추가하여 보다 복잡한 전략 환경으로 확장할 예정이다. 또한 적의 공격 패턴 및 이동 방식까지 adversarial curriculum에 포함하여 정책의 일반화 성능(generalization performance)을 향상시키고자 한다.

참고문헌

- [1] V. Mnih et al., "Human-level control through deep reinforcement learning," *Nature*, 2015.
- [2] R. S. Sutton and A. G. Barto, *Reinforcement Learning: An Introduction*, MIT Press, 2018.
- [3] J. Schulman et al., "Proximal policy optimization algorithms," arXiv:1707.06347, 2017.
- [4] Y. Bengio et al., "Curriculum learning," *ICML*, 2009.
- [5] S. Narvekar et al., "Curriculum learning for reinforcement learning domains: A framework and survey," *JMLR*, 2020.
- [6] R. Florensa et al., "Automatic goal generation for reinforcement learning agents," *ICML*, 2018.
- [7] W. Liu et al., "Robust adversarial reinforcement learning," *ICML*, 2018.
- [8] M. Dennis et al., "Emergent complexity and zero-shot transfer via unsupervised environment design," *NeurIPS*, 2020.
- [9] M. Jiang et al., "Prioritized level replay," *ICML*, 2021.
- [10] O. Vinyals et al., "Grandmaster level in StarCraft II using multi-agent reinforcement learning," *Nature*, 2019.
- [11] Unity Technologies, "Unity ML-Agents Toolkit."
- [12] A. Juliani et al., "Unity: A general platform for intelligent agents," arXiv:1809.02627, 2018.